

Modelos de lenguaje pequeños para decidir en combate en Pokémon Blue

El prompting estructurado arregla el formato de la acción, no la calidad de la decisión

Deliverable 1 • Generative Artificial Intelligence (580694) • Universidad de Concepción

Equipo: **Pedro Dañobeytia • Rafael Fernández • Cristian Gonzalez • Daniel Gonzalez**

Repositorio: **github.com/Rafaefe/AlBattlesInPokemon**

1. ESPECIFICACIÓN DE LA TAREA

El modelo actúa como **módulo de decisión de combate** de un agente de Pokémon Blue.

Entrada. Estado de combate estructurado: tipo(s), % de HP y velocidad de ambos Pokémon, más los cuatro movimientos con *nombre, tipo, potencia, precisión y PP restantes*.

Salida. Exactamente una etiqueta ejecutable: MOVE_1, MOVE_2, MOVE_3 o MOVE_4.

Qué cuenta como correcto. La etiqueta que maximiza una política ofensiva explícita y determinista,

$$\text{score} = \text{potencia} \times \text{precisión} \times \text{STAB} \times \text{efectividad}$$

con $\text{score} = 0$ cuando $\text{PP} = 0$: ground truth reproducible y auditable caso por caso.

Por qué no es trivial. Los cinco atributos compiten: el movimiento de mayor potencia es el óptimo en solo 19 de 30 estados, y las inmunidades de Gen I (Eléctrico → Tierra, Normal → Fantasma) anulan la opción que parece más fuerte. El modelo debe *combinar* restricciones, no recuperar un dato.

2. EXPERIMENTO PILOTO (V1)

Modelo. Qwen2.5-1.5B-Instruct, decodificación greedy, max_new_tokens=48, semilla 20260830, mismo system prompt en ambas condiciones.

Diseño. 30 estados sintéticos (10 EASY / 10 MEDIUM / 10 HARD, según la razón entre el mejor y el segundo mejor score: $\geq 1,80 / 1,25 - 1,80 / 1,01 - 1,25$).

Los mismos 30 estados van a los dos prompts → **60 inferencias**, offline y sin el emulador en la medición.

Condiciones. DIRECT = petición natural (“What move would you use next?”). STRUCTURED = mismo estado, checklist de razonamiento y contrato de salida estricto (solo MOVE_N).

Métricas. STRICT (responde exactamente MOVE_N y es ejecutable) · INTERP (intención recuperable) · ACC (coincide con el ground truth) · regret (mejor score perdido).


Prompt	STRICT	INTERP	ACC	EXEC.-C.
DIRECT	0,0%	36,7%	3,3%	0,0%
STRUCTURED	96,7%	96,7%	16,7%	16,7%

Regret medio: DIRECT 0,41; STRUCTURED 0,49. $n = 30$ estados por condición.

3. DIAGNÓSTICO DEL FALLO

El prompting estructurado *casi eliminó* el problema de interfaz (STRICT 0% → 96,7%; una respuesta siguió siendo inejecutable), así que el agente ya puede ejecutarse solo. No resolvió la tarea: la calidad de la decisión queda **por debajo del azar**.

El modelo responde por posición, no por estado. En las 29 respuestas parseables devuelve MOVE_2 veinte veces y MOVE_1 *ninguna*, mientras que la acción óptima está repartida casi uniformemente entre las cuatro posiciones ($\chi^2(3) = 31,8$; $p < 10^{-6}$ frente a la uniforme).



Solo acierta cuando la respuesta resulta ser MOVE_2. Tasa de acierto según la posición del movimiento óptimo: MOVE_1 0/7, MOVE_2 4/9, MOVE_3 1/8, MOVE_4 0/6.

Política	Exactitud
Qwen2.5-1.5B, prompt estructurado	16,7%
Elección aleatoria uniforme (4 opciones)	25,0%
Política constante “siempre MOVE_2”	30,0%
max(potencia × precisión), PP > 0	53,3%
max(potencia) — ignora los tipos	63,3%

Diagnóstico

El principal cuello de botella observado **no** es el formato de salida, sino la **selección de acciones al combinar múltiples restricciones**: al ponderar efectividad, STAB, potencia, precisión y PP sobre cuatro candidatos a la vez, el modelo colapsa en un **sesgo de posición** casi independiente del estado. Una heurística de una línea que ignora la tabla de tipos es **3,8 veces** más precisa.

4. ¿ES EL GROUND TRUTH EL PROBLEMA?

Una puntuación baja frente a una política hecha a mano podría significar que la política está mal. Tres comprobaciones lo descartan: son errores indefendibles bajo *cualquier* regla.

- Movimiento sin efecto.** Caso 16 (abajo): *Thunderbolt* (Eléctrico) contra un rival *Tierra* — inmune, 0 de daño.
- Movimiento inejecutable.** Caso 29: eligió un movimiento con **PP = 0**; el agente no puede emitirlo.
- Peor opción estricta** elegida en **6 de 29** respuestas (21 %): la de menor score de las cuatro.

CASO 16 - jugador Flying (41% HP) vs Ground (53%)

MOVE_1	Psybeam	Psychic	P65	A100	score	65,0
MOVE_2	Thunderbolt	Electric	P95	A100	score	0,0
MOVE_3	Rock Throw	Rock	P50	A65	score	16,3
MOVE_4	Ember	Fire	P40	A100	score	40,0

ground truth = MOVE_1 modelo = **MOVE_2**

Se queda con el número de potencia más alto e ignora la inmunidad que lo vuelve inútil.

Sin gradiente de dificultad. La exactitud estructurada es EASY 2/10, MEDIUM 1/10, HARD 2/10. Un razonamiento graduado debería degradarse al subir la dificultad; un sesgo de posición no — y no lo hace.

5. AMENAZAS A LA VALIDEZ Y CORRECCIÓN PARA LA V2

- T1.** A DIRECT nunca se le pidió MOVE_N, así que su 0% de STRICT es cierto por construcción; se reporta como línea base de interfaz, no como evidencia de razonamiento.
- T2.** max_new_tokens=48 truncó las respuestas libres de DIRECT y desinfla su 36,7% de INTERP.
- T3.** La política de referencia es solo ofensiva: no cubre movimientos de estado, cambios, objetos ni varios turnos.

v2. Ambos prompts exigen el mismo contrato MOVE_N, así la única diferencia es el andamiaje de razonamiento; $n = 50$ estados, cada uno repetido con sus movimientos **permutados**, lo que mide el sesgo de posición de forma directa.

6. MODELOS PROPUESTOS

Modelo	Par.	MMLU	IFEval	GSM8K	fp16
Qwen2.5-1.5B-Instr.	1,5B	50,7	42,5	73,2	3,1 GB
Llama-3.2-3B-Instr.	3,2B	63,4	77,4	77,7	6,4 GB
Phi-3.5-mini-instr.	3,8B	69,0	n.r.	86,2	7,6 GB

Fuentes: fichas oficiales de Qwen2.5, Llama 3.2 y Phi-3.5-mini (referencias en el repositorio). Los protocolos difieren, así que ubican a los modelos en una clase más que ordenarlos. n.r. = no reportado.

- IFEval: seguimiento de instrucciones.** Mide obediencia a formatos restringidos, que es lo que necesita el controlador. Con el prompt estructurado Qwen ya alcanza 96,7% pese a su 42,5, así que el formato *no* es lo que separa a los candidatos.
- GSM8K: razonamiento de varios pasos.** Proxy público más cercano al paso que sí falla: combinar varios atributos numéricos. Phi-3.5-mini lidera con **86,2** usando solo 3,8B: la prueba directa de si ese cuello de botella se levanta.

Qwen2.5-1.5B es además la línea base: el único con un perfil *medido* aquí. La tarea no exige de forma evidente un modelo de 8B, lo que motiva evaluar candidatos bastante más pequeños.

7. VIABILIDAD DE EJECUCIÓN Y REPRODUCIBILIDAD

El piloto **ya se ejecutó de principio a fin** en el hardware del equipo: 60 inferencias, **105,5 min** en CPU, de forma determinista (greedy, semilla fija). Memoria estimada como parámetros × 2 bytes (fp16) más caché KV: los tres caben en una Colab T4 gratuita (16 GB). El repositorio incluye el benchmark, sus cuatro archivos de resultados y la demo en PyBoy, que se mantiene *fuera* del circuito de medición para no confundir errores del emulador con fallos del modelo.